

yahoo財經新聞

-最大交易市場-



組別:2 成員:李晨愷

目錄

主題 1 前言

主題 2 動機與重要性

主題 3 關鍵詞

主題 4 文字雲

主題 5

文字情感分析

主題 6 斷詞

前言

在金融資訊爆炸的數位時代，Yahoo 財經作為全球流量最大的財經新聞聚合平台在每日產出數以萬計的新聞，不僅隱藏著投資人情感、政策風向與企業動態。

過去，分析師需要閱讀大量報告來判斷市場走勢；而今天,透過文字探勘技術，我們就能將非結構化的新聞文字轉化為結構化的有用訊號。

本報告旨在利用文字探勘技術，剖析yahoo 財經新聞在 2026 年複雜政經環境下演變與市場反應。



動機與重要性

動機

文字探勘能捕捉正要發生的事件,透過情感分析新聞標題的語氣（正向/負向/中立），讓我們可以根據情報來預判市場未來的臨界點，從而獲得領先於大盤的洞察

重要性

在資訊大爆發的時代，比的是誰能最快從雜訊中提取核心邏輯，誰就擁有最大優勢。文字探勘能自動化地從數萬篇報導中精煉出影響市場的關鍵敘事，幫助投資者在宛如戰場的交易競爭中快速識別真正的有用新聞。

流程圖

階段1

爬蟲

階段2


關鍵詞

階段3

文字雲

斷詞

文字情感分析



爬蟲

內文抓取：`get_news_content`

運作方式：

使用 `requests.get()` 直接向伺服器請求 HTML 原始碼，再用 `BeautifulSoup` 進行標籤解析。

調度中心：`run_enhanced_scraper`

第一階段（抓取清單）：

在 `run_enhanced_scraper` 中，先爬取 Yahoo 股市新聞的首頁撈出前50篇新聞的「標題」與「詳細內文連結」。

第二階段（深入內文）：

利用迴圈（For Loop）化身為點擊專員，逐一「點進去」這 50 個連結，呼叫 `get_news_content` 函式去抓取每篇新聞內頁的「發布時間」與「完整正文」。

爬蟲

- 去重處理： `drop_duplicates` 移除首頁重複出現的新聞。
- 雜訊去除： 透過 `len(txt) > 20 and "贊助商" not in txt and "廣告" not in txt` 移除圖表註解或「點我分享」等無關字樣。
- 格式轉換： 將結果導出為 `UTF-8` 編碼的 `CSV`，確保 `Excel` 開啟不亂碼。

正在抓取第 40 篇：金溥聰、王光慈、蕭旭岑隔空混戰...
正在抓取第 41 篇：富邦金股價進逼百元、股息殖利率...
正在抓取第 42 篇：苗豐強當年為何放棄英特爾回台？...
正在抓取第 43 篇：台灣百貨男客只剩15%？新光三...
正在抓取第 44 篇：AI來了先砍誰？Cloudfl...
正在抓取第 45 篇：誇張！台新銀理專到高齡長者家盜...
正在抓取第 46 篇：AI打敗玄學？巴逆逆才剛買欣興...
正在抓取第 47 篇：台股市值超印度成全球第五！印媒...
正在抓取第 48 篇：潤泰集團總裁尹衍樑辭世 遺作松...
正在抓取第 49 篇：四貸同堂買爆台股！今「無法下單...
正在抓取第 50 篇：【Follow法人】外資獵殺面...
正在抓取第 51 篇：張菲神操作賣鴻海爽賺5億！費...
正在抓取第 52 篇：台塑化超額配息1.2元！董事...
正在抓取第 53 篇：台積電成台股拖油瓶？不敗教主改...
正在抓取第 54 篇：永豐金通過1.3元股利 2家子...

完成 資料已儲存至 `yahoo_news_enhanced.csv`

	標題	連結	發布時間	新聞內文
0	麥味登母公司營收增20% 發6元股利	https://tw.stock.yahoo.com/news/%E6%8F%9A%E7%A...	2026-05-26T08:05:51.000Z	加入為 Google 偏好來源\n將 Yahoo 設為首選來源，在 Google 上查看更多...
1	擔憂「旺季不旺」市場血洗面板雙虎	https://tw.stock.yahoo.com/news/%E9%9D%A2%E6%9...	2026-05-26T07:40:00.000Z	加入為 Google 偏好來源\n將 Yahoo 設為首選來源，在 Google 上查看更多...
2	增持台積電到近4成 00631L大變身	https://tw.stock.yahoo.com/news/00631L%E8%AE%8...	2026-05-26T07:37:54.000Z	加入為 Google 偏好來源\n將 Yahoo 設為首選來源，在 Google 上查看更多...
3	老黃點台灣罩門 經部急喊供電無虞	https://tw.stock.yahoo.com/news/%E9%BB%83%E4%B...	2026-05-26T07:48:38.000Z	加入為 Google 偏好來源\n將 Yahoo 設為首選來源，在 Google 上查看更多...
4	口袋證券系統癱瘓 喊話會承擔損失	https://tw.stock.yahoo.com/news/%E5%8F%A3%E8%A...	2026-05-26T07:32:00.000Z	加入為 Google 偏好來源\n將 Yahoo 設為首選來源，在 Google 上查看更多...

關鍵詞

```
import jieba
from collections import Counter
import re

# 1. 合併所有新聞內文
all_text = "".join(df_enhanced['新聞內文'].astype(str).tolist())

# 2. 清理文本：只保留中文字與英數字，移除標點符號
clean_text = re.sub(r'[^\u4e00-\u9fa5a-zA-Z0-9]', '', all_text)

# 3. 使用 jieba 進行斷詞
# 首次執行可能需要下載字典
words = jieba.cut(clean_text)

# 4. 過濾掉單一個字（通常是介系詞或無意義詞）以及自定義停用詞
stopwords = {'一個', '我們', '公司', '目前', '表示', '提供', '可以', '可能', '就是', '今天', '今年', '營收', '指出', '整體', '偏好', '報導', '方面', '加入', '查看', '更多', '精彩', '來源將', '不過', '成長'}
filtered_words = [word for word in words if len(word) > 1 and word not in stopwords]

# 5. 統計詞頻
word_counts = Counter(filtered_words)
top_keywords = word_counts.most_common(20)

# 6. 轉換為 DataFrame 顯示結果
df_keywords = pd.DataFrame(top_keywords, columns=['關鍵字', '出現次數'])

print("--- 新聞內文最常出現的關鍵字 Top 20 ---")
display(df_keywords)
```

關鍵詞

前20名新聞常出現的關鍵詞:

- 寒武紀科技:是北京市一家專注於人工智慧晶片設計與銷售的民營企業。

stopwords = { '一個', '我們', '公司', '目前', '表示', '提供', '可以', '可能', '就是', '今天', '今年', '營收', '指出', '整體', '偏好', '報導', '方面', '加入', '查看', '更多', '精彩', '來源將', '不過', '成長', '首選來源', '以及', '布局', '市場', '美元', 'Yahoo', '設為', '億元', '指數', '全球', '投資人', '建議', '去年', '顯示', '平台', '主要', '包括', '影響', '分析', '表現', '10', '認為', '提升', '產業', '數據', '價格', '資料', '基金', '交易', '法人', '中心', '股價', '延伸', '重要', '上市', '經濟', '成本', '2026', '董事', '增加', '目標', '報告', '此外', '合作', '價差', '同步', '超過', '規模', '雖然', '其中', '投資', '工作', '今日', '成交量', '評估', '穩定', '夥伴', '國際', '資金', '獲利', '企業', '美股', '萬元', '政府', '人民', '公布', '同時', '新聞網', '20', '台幣', '根據', '關鍵', '成交', '台股', '相關', '股票', '證券', '金額', '首季', '第一季', '政策', '程式', '營運', '下跌', '方案', '大幅', '進行', '收益', '閱讀', '法律', '策略', '股市', '收入', '近期', '就業', '預期', '持續', '工程', '提出', '操作', '使用', '計畫', '大漲', '銀行', '停火', '元漲', '跌幅', '新聞', '最大', '將持續', 'ClaudeCode', '消費者', '調整', '未來', '需求', '官兵', '開始', '參考', '時間', '優勢', '審慎', '以來', '股東', '模型', '15', '創新', '商家', '不到', '成為', '龍頭', '不會', '受惠', '完成', '能力', '銷售', '因此', '最新', '需要', '內容', '新高', ',,,,,' }

	關鍵字	出現次數
0	AI	138
1	Google	108
2	晶片	70
3	美國	42
4	科技	40
5	新高	37
6	風險	33
7	台灣	31
8	ETF	31
9	14	30
10	12	26
11	伊朗	25
12	資產	24
13	客戶	24
14	帶動	23
15	發展	23
16	推出	23
17	2025	23
18	寒武	23
19	中國	22

文字雲

```
from wordcloud import WordCloud

chinese_font = '/usr/share/fonts/opentype/noto/NotoSansCJK-Regular.ttc'

word_freq = dict(zip(df_keywords['關鍵字'], df_keywords['出現次數']))

wc_chinese = WordCloud(
    font_path=chinese_font,
    background_color='white',
    width=800,
    height=400,
    colormap='viridis'
).generate_from_frequencies(word_freq)

plt.figure(figsize=(12, 6))
plt.imshow(wc_chinese, interpolation='bilinear')
plt.axis('off')
plt.title('News Keywords Word Cloud (Corrected Font)', fontsize=16)
plt.show()
```

文字雲

News Keywords Word Cloud (Corrected Font)



文字情感分析

```
pos_score = sum(1 for word in pos_words if word in text)
neg_score = sum(1 for word in neg_words if word in text)
```

```
import pandas as pd
import matplotlib.pyplot as plt
import matplotlib.font_manager as fm

#定義簡單的情感字典 (正面與負面關鍵字)
pos_words = ['創新高', '成長', '大漲', '強彈', '利多', '優於預期', '買進', '獲利', '成功', '看好', '噴發', '新猷', '反彈']
neg_words = ['下跌', '年減', '風險', '戰火', '壓力', '撤離', '調漲', '倒地', '警戒', '拋售', '虧損', '下修', '動盪', '慘', '跌幅']

def calculate_sentiment(text):
    text = str(text)
    pos_score = sum(1 for word in pos_words if word in text)
    neg_score = sum(1 for word in neg_words if word in text)

    if pos_score > neg_score:
        return '正面 (Positive)'
    elif neg_score > pos_score:
        return '負面 (Negative)'
    else:
        return '中性 (Neutral)'

df_enhanced['情感傾向'] = df_enhanced['新聞內文'].apply(calculate_sentiment)
sentiment_counts = df_enhanced['情感傾向'].value_counts()

font_path = '/usr/share/fonts/opentype/noto/NotoSansCJK-Regular.ttc'
prop = fm.FontProperties(fname=font_path)

plt.figure(figsize=(8, 8))
colors = ['#4CAF50', '#FFC107', '#F44336'] # 綠, 黃, 紅


plt.pie(sentiment_counts, labels=sentiment_counts.index, autopct='%1.1f%%',
        startangle=140, colors=colors, textprops={'fontproperties': prop})

plt.title('新聞內容情感分析分佈', fontproperties=prop, fontsize=16)
plt.show()

print("—— 情感分類預覽 ——")
display(df_enhanced[['標題', '情感傾向']].head(10))
```

文字情感分析

新聞內容情感分析分佈



pos_words =

{'創新高', '成長', '大漲', '強彈', '利多', '優於預期', '買進', '獲利', '成功', '看好', '噴發', '新猷', '反彈'}

neg_words =

{'下跌', '年減', '風險', '戰火', '壓力', '撤離', '調漲', '倒地', '警戒', '拋售', '虧損', '下修', '動盪', '慘', '跌幅'}

斷詞

```
import pandas as pd
import matplotlib.pyplot as plt
import matplotlib.font_manager as fm
import jieba

# 1. 定義擴展後的市場關鍵字
market_keywords = {
    'AI市場': ['AI', '輝達', 'NVIDIA', '伺服器', '算力', '人工智慧'],
    '電動車': ['特斯拉', '電池', '充電樁', '鋰電', '電動車', '鴻海'],
    '半導體': ['台積電', '晶圓', '封測', 'IC設計', '聯電', '南亞科'],
    '綠能/儲能': ['太陽能', '離岸風電', '儲能', '重電', '中興代', '華城'],
    '金融權點': ['央行', '升息', '降息', '銀行', '金控', '台新', '新光'],
    '航運/貿易': ['航運', '長榮', '陽明', '萬海', '貨櫃', '運價']
}

# 2. 定義分析函式
def analyze_market_expanded(text):
    words = list(jieba.cut(str(text)))
    results = {k: 0 for k in market_keywords.keys()}
    for word in words:
        for market, keywords in market_keywords.items():
            if word in keywords:
                results[market] += 1
    return results


# 3. 執行分析
market_results = df_enhanced['新聞內文'].apply(analyze_market_expanded)
total_market_scores = pd.DataFrame(list(market_results)).sum()
df_market_analysis = total_market_scores.reset_index()
df_market_analysis.columns = ['Market Segment', 'Mention Count']

# 4. 設定字體與繪圖
font_path = '/usr/share/fonts/opentype/noto/NotoSansCJK-Regular.ttc'
fm.fontManager.addfont(font_path)
prop = fm.FontProperties(fname=font_path)

plt.figure(figsize=(12, 6))
plt.bar(df_market_analysis['Market Segment'], df_market_analysis['Mention Count'],
        color=['#4285F4', '#EA4335', '#FBBC05', '#34A853', '#9334E6', '#FF6D01'])

plt.title('多樣化市場關注度分析 (關鍵字出現次數)', fontproperties=prop, fontsize=16)
plt.ylabel('出現頻率', fontproperties=prop, fontsize=12)
plt.xlabel('市場區隔', fontproperties=prop, fontsize=12)
plt.xticks(fontproperties=prop, rotation=45)
plt.grid(axis='y', linestyle='--', alpha=0.7)
```

斷詞



THANK YOU

